

Multi Cycle Consistent Adversarial Networks for Multi Attribute Image to Image Translation

Seok Hee Jo*, Kyu Cheol Cho*

*Student, Dept. of Computer Science, Inha Technical College, Incheon, Korea

*Professor, Dept. of Computer Science, Inha Technical College, Incheon, Korea

[Abstract]

Image-image translation is a technology that creates a target image through input images, and has recently shown high performance in creating a more realistic image by utilizing GAN, which is a non-map learning structure. Therefore, there are various studies on image-to-image translation using GAN. At this point, most image-to-image translations basically target one attribute translation. But the data used and obtainable in real life consist of a variety of features that are hard to explain with one feature. Therefore, if you aim to change multiple attributes that can divide the image creation process by attributes to take advantage of the various attributes, you will be able to play a better role in image-to-image translation. In this paper, we propose Multi CycleGAN, a dual attribute transformation structure, by utilizing CycleGAN, which showed high performance among image-image translation structures using GAN. This structure implements a dual transformation structure in which three domains conduct two-way learning to learn about the two properties of an input domain. Experiments have shown that images through the new structure maintain the properties of the input area and show high performance with the target properties applied. Using this structure, it is possible to create more diverse images in the future, so we can expect to utilize image generation in more diverse areas.

▶ **Key words:** image to image translation, GAN, Multi attribute translation, CycleGAN

[요 약]

이미지-이미지 변환은 입력 이미지를 통해서 목적 이미지를 만들어내는 기술로 최근 비지도 학습 구조인 GAN을 활용하여 더 실제와 같은 이미지를 만들어내는 높은 성과를 보였다. 이에 따라 GAN을 활용한 이미지-이미지 변환 연구는 다양하게 진행되고 있다. 이때 일반적으로 이미지-이미지 변환은 하나의 속성 변환을 목표로한다. 그러나 실제 생활에서 사용되고 얻을 수 있는 자료들은 한 가지 특징으로 설명하기 힘든 다양한 특징으로 이루어진다. 그래서 다양한 속성을 활용하기 위하여 속성별로 이미지 생성 과정을 나누어 학습할 수 있도록 하는 다중 속성 변환을 목표로 한다면 더 이미지-이미지 변환의 역할을 잘 수행할 수 있을 것이다. 본 논문에서는 GAN을 활용한 이미지-이미지 변환 구조 중 높은 성과를 보인 CycleGAN을 활용해 이중 속성 변환 구조인 Multi CycleGAN을 제안한다. 이 구조는 입력 도메인을 두 가지의 속성에 대하여 학습하기 위하여 3개의 도메인이 양방향 학습을 진행하는 이중 변환 구조를 구현하였다. 새로운 구조를 통해 생성된 이미지와 기존 이미지-이미지 변환 구조들을 통해 생성된 이미지를 비교할 수 있도록 실험을 진행하였다. 실험 결과 새로운 구조를 통한 이미지는 입력 도메인의 속성을 유지하며 목표한 속성이 적용되는 높은 성능을 보였다. 이 구조를 활용한다면 앞으로 더 다양한 이미지를 생성하는 일이 가능지기 때문에 더 다양한 분야에서의 이미지 생성의 활용을 기대할 수 있다.

▶ **주제어:** 이미지 변환, 적대적 생성 신경망, 다중 속성 변환, CycleGAN

- First Author: Seok Hee Jo, Corresponding Author: Kyu Cheol Cho
- *Seok Hee Jo (joseokhee44@gmail.com), Dept. of Computer Science, Inha Technical College
- *Kyu Cheol Cho (kccho@inhac.ac.kr), Dept. of Computer Science, Inha Technical College
- Received: 2020. 06. 23, Revised: 2020. 08. 25, Accepted: 2020. 08. 25.

I. Introduction

이미지-이미지 변환은 원본 이미지(이하 입력 도메인)를 통하여 목표하는 이미지(이하 목적 도메인)를 수정 또는 생성해내는 기술로 많은 연구가 진행되고 있으며 많은 분야에서 사용이 되고 있다. 예를 들면 이미지 스타일 전환 [2], 이미지 재생산 [13], 영상 분할 [3] 등의 분야에서 사용되고 있다. 하지만 이미지-이미지 변환은 비가 내리는 사진에서 비를 지우거나, 흐릿한 부분을 복원하거나, 사진을 그림으로 바꾸는 등의 작업을 수행하기 때문에 목적으로 하는 사진의 원본을 구하는 일은 매우 어렵고 비싸며 불가능한 경우도 있다. 그래서 최근에 이루어진 많은 이미지-이미지 변환에 관한 연구는 비지도 학습을 기반으로 이루어지고 있다 [10]. 비지도 학습 중에서도 이미지 생성을 위한 학습 모형은 대표적으로 Generative adversarial networks (이하 GAN) [4]가 사용된다. GAN을 사용한 이미지 생성이 더 사실적인 이미지를 만들어내는 높은 성능을 보이자 GAN을 사용한 다양한 이미지-이미지 변환 구조들이 등장하였고 높은 성과를 보였다 [16].

그러나 GAN을 활용한 구조들은 보통 단일 속성 변환에 적합한 구조이거나(ex 남자 → 여자) 다중 도메인 변환(ex 남자 → 여자, 남자 → 노인) 위한 구조이다. 단일 속성 변환 구조는 목적 데이터 셋의 구성이 필수적인데 경우에 따라 원하는 목적 데이터의 양이 부족할 수도 있고 구하기 힘든 경우도 발생한다. 따라서 본 연구에서는 학습을 위한 데이터 셋이 가지고 있는 다양한 속성에 따라 분할하여 구성할 수 있도록 다중 속성 변환에 특화된 구조를 제시한다. 이를 통해 기존의 구조들보다 데이터 셋의 의존도를 줄이면서 이미지-이미지 변환 역할을 수행할 수 있을 것이다.

본 연구 구성은 다음과 같다. 2장에서는 관련 연구에 관하여 기술한다. 3장에서는 본 논문에서 제시하는 프레임워크의 구조를 기술한다. 4장에서는 실험에 사용된 데이터와 실험을 보여준다. 5장에서는 결론 및 향후 연구 방향에 대하여 서술한다.

II. Related works

1. GAN

GAN은 비지도 학습 방식의 이미지 생성 구조이다. GAN은 생성자(generator)와 구분자(discriminator)로 구성된다. 생성자는 임의의 값을 입력받아 이미지를 생성해내고 구분자는 이렇게 생성된 이미지를 목표로 하는 실제 이미지와 비교하게 된다.

$$L_{GAN}(D, G) = E_{y \sim p_{data}(y)} [\log D(y)] + E_{x \sim p_{data}(x)} [\log(1 - D(G(x)))] \quad \dots\dots(1)$$

L : 손실함수 D : 구분자 G : 생성자 x, u : 실제 값

$x, y \sim p_{data}(x, y)$: 실제 데이터분포 중 임의 추출한 값

식 (1)과 같은 손실함수를 사용한다. 구분자(D)는 식 (1)의 함수를 최대화하고 생성자(G)는 이 함수를 최소화하는 방향으로 최적화를 진행한다. 최적화 과정을 통해서 구분자는 진짜 이미지와 가짜 이미지를 더욱 정확하게 판별하게 되고 생성자는 구분자를 더 잘 속이기 위해 점점 더 높은 수준의 가짜 이미지를 만들게 된다. GAN이라는 이미지 생성 구조는 높은 성과를 보였고 이미지 생성이 필요한 다양한 분야에서의 사용도 많아졌다 [2][13][3]. 기존의 GAN의 성능을 향상시킨 다양한 구조도 많이 제시되고 있다. [12][14]

2. CycleGAN

GAN은 이미지 생성이 필요한 다양한 분야에서 많이 사용되어 졌고 그중 하나가 이미지-이미지 변환이다. 그중 CycleGAN은 Cycle-Consistent [15] 개념을 GAN에 적용하여 이미지-이미지 변환에서 높은 성과를 보인 구조이다. 이 구조는 2개의 생성자와 2개의 구분자를 가진다. CycleGAN은 일반적인 GAN과는 다르게 생성자에 이미지를 입력한다. 입력된 이미지(식(2)의 x, y)를 통하여 생성자(G, F)는 임의의 이미지($G(x), F(y)$)를 생성하게 되고 생성된 이미지는 목적 이미지(y, x)와 구분자(D_y, D_x)에 의해 비교된다. 이때 입력된 이미지(x)의 원래 형태를 유지하기 위해서 생성된 이미지($G(x)$)를 새로운 생성자(F)를 이용해 원래 이미지로 복원한다. 이러한 방식으로 원래 이미지로 복원할 수 있을 만큼의 변경만 진행되어 이미지-이미지 변환의 역할을 할 수 있게 된다.

$$L_{cyc}(G, F) = E_{x \sim P_{data}(x)} [\|F(G(x)) - x\|_1] + E_{y \sim P_{data}(y)} [\|G(F(y)) - y\|_1] \quad \dots\dots(2)$$

F : X 생성자 G : Y 생성자

CycleGAN은 이미지-이미지 변환을 위하여 식(1)의 GAN loss와 함께 식(2)와 같은 Cycle consistency loss를 사용하여 원래 형태를 유지할 수 있도록 한다.

$$L = L_{GAN}(G, D_Y, X, Y) + L_{GAN}(F, D_X, Y, X) + L_{cyc}(G, F) \quad \dots\dots\dots(3)$$

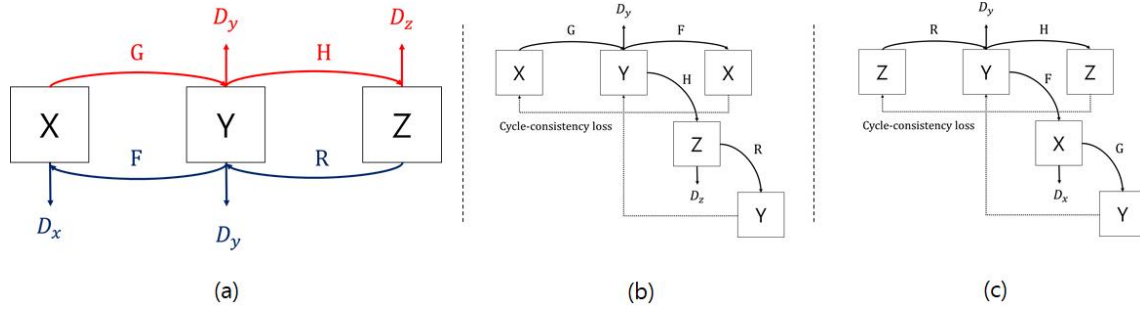


Fig. 1. Multi CycleGAN Structure

최종적으로 식(3)과 같은 손실함수를 사용한다. GAN loss를 두 번 사용함으로써 입력 도메인을 목적 도메인으로 만들도록 하고 동시에 목적 도메인을 입력 도메인으로 만들 수 있도록 학습한다. 이를 통해 생성자를 중복 학습하는 양방향 학습을 진행하고 더욱 사실적인 사진을 만들 수 있도록 한다.

또한, CycleGAN은 높은 성능을 위해 사용한 몇 가지 특징이 있다. 첫 번째로 손실 함수를 기존의 Cross entropy loss 형태가 아닌 Least square GAN(이하, LSGAN)[12]의 MSE(Mean squared error) loss 형태를 사용하여 안정성과 더 높은 성과를 보이게 하였다. 두 번째로 생성자의 구조를 ResNet[5]의 Residual block을 사용하여 더 많은 특징을 유지하면서 변환될 수 있도록 하였다. 이런 과정을 통해 이미지-이미지 변환역할을 잘 수행하는 높은 성과를 보일 수 있었다.

III. Multi Cycle Consistent Adversarial network

1. Object Structure

본 연구에서 제시하는 학습 모델은 CycleGAN을 응용하여 다중 속성 변환에 적합한 구조로 제작하였으며, Multi cycle consistency loss라는 새로운 손실 함수를 제시한다. 전체적인 구조는 Fig. 1의 (a)와 같다. 입력 도메인 X 를 통하여 생성한 값이 목적 도메인인 Y 와 Z 의 속성을 모두 포함할 수 있도록 3가지의 도메인을 순환적으로 학습한다. 이중 속성 변환 구조 구현을 위해서 추가적인 순환과정과 세부사항을 추가하였다.

Fig. 1.의 (b)와 (c)는 각각 순방향과 역방향 학습을 도식화한 모습이다. 모든 생성자는 양방향 학습을 진행하며 생성자 별로 같은 도메인을 입력받아 같은 도메인을 출력한다. 이를 통해 중복 학습을 진행하는 양방향 학습의 장점을 이용할 수 있게 한다.

Fig. 1의 X, Y, Z 는 도메인을 의미하고 G, F, R, H 는 각각 다른 도메인을 생성하는 생성자이다. D_x, D_y, D_z 는 생성자를 통해 생성된 가짜 이미지를 진짜 이미지와 비교하는 구분자이다.

1.1 Adversarial Loss

GAN을 활용하는 Multi CycleGAN은 생성자와 구분자를 학습시키기 위해 Adversarial loss를 사용한다. Fig. 1에서 X 를 통해 Y 를 생성하는 과정은 생성자(G)는 입력 도메인(X)을 통해서 목적 도메인($G(x)$)을 생성한다. 구분자(D_y)는 생성된 목적 도메인($G(x)$)을 실제 목적 도메인(Y)과 비교하는 과정을 통하여 생성자와 구분자가 경쟁적으로 손실함수를 최적화하며 학습이 진행된다. 손실함수는 식 (1)의 GAN loss와 같이 사용한다.

이런 과정을 통하여 생성자 F 는 구분자 D_x , H 는 D_z 와 경쟁적으로 학습하게 된다. 이 때 특수하게 생성자 R 은 더 사실적인 $R(z)$ 를 만들기 위하여 생성자 G 에서 사용하는 구분자 D_y 를 중복해서 사용한다. 중복 사용을 통해 D_y 는 더욱 다양한 가짜 Y 도메인을 구분할 수 있게 되고 D_y 와 경쟁적으로 최적화가 진행되는 생성자 G, R 은 더욱 사실적인 가짜 Y 값을 생성할 수 있다.

1.2 Multi Cycle Consistency Loss

Adversarial loss를 단독으로 사용하면 입력 도메인과는 무관하게 목적 도메인을 생성하는 일반적인 GAN과 같이 이미지를 생성한다. 그러므로 입력 도메인이 목적 도메인에 영향을 줄 수 있도록 Adversarial loss와 함께 Cycle consistency loss를 사용한다. 이를 통해 목적 도메인은 입력 도메인의 형태를 유지할 수 있는 범위 내에서 한정적인 변환을 하게 되고 이를 통해 이미지-이미지 변환을 수행할 수 있게 된다.

본 연구에서는 최종 목표인 이중 속성 변경을 위해 4가지의 생성자를 통해 생성되는 값에 대하여 모두 Cycle consistency를 적용하기 위하여 Multi cycle consistency를 사용하였고, 식(4)와 같이 표현된다.

$$\begin{aligned} L_{cyc}(G, F, R, H) &= E_{x \sim P_{data}(x)} [\|F(G(x)) - x\|_1] \\ &+ E_{z \sim P_{data}(z)} [\|H(R(z)) - z\|_1] \\ &+ E_{G(x) \sim P_{data}(G(x))} [\|R(H(G(x))) - G(x)\|_1] \cdots \cdots (4) \\ &+ E_{R(z) \sim P_{data}(R(z))} [\|G(F(R(z))) - R(z)\|_1] \end{aligned}$$

Fig. 1의 입력 도메인으로 사용되는 x 와 z 는 각각 2개의 생성자를 통해 결과 값을 생성한다. 이때 원래의 형태를 유지하기 위해서 다른 생성자를 통해 입력 값을 재생산하고 이를 원본과 비교하는 과정을 거친다. 이런 과정에서 식(4)의 $G(x)$ 와 같이 입력 도메인으로 생성된 값을 사용하는 경우에는 재생산한 값을 원본(Y)과 비교 하는 것이 아닌 입력으로 사용한 생성 값과 비교한다. 이를 통해 형태를 유지하며 목표로 하는 이중 속성 변환을 수행할 수 있도록 한다.

1.3 Identity Mapping

Multi cycle consistency loss를 통해 이중 속성 변환 모델을 구현할 수 있다. 하지만 중간 생성자는 초기 학습 과정에서 임의의 값을 입력받는 것처럼 학습이 진행되어 학습에 어려움을 겪는다. 예를 들어 Fig. 1의 (b)에서 도메인 Y 를 입력으로 사용하는 생성자 H 는 실제 Y 값을 입력받는 것이 아니라 생성자 G 를 통해 만들어진 $G(x)$ 를 입력으로 사용하여 학습을 진행한다. $G(x)$ 를 입력받으면 초기에는 임의의 값을 통하여 학습이 진행되어 유지해야 하는 형태를 인지하지 못하고 학습이 진행된다. 그래서 $G(x)$ 를 실제 입력 도메인과 같이 현실적인 사진으로 만들어 학습에 도움을 주기 위하여 Identity mapping을 사용한다. Identity mapping은 생성자에게 입력 도메인이 아닌 목적 도메인을 입력해주고 목적 도메인을 생성하도록 하는 것이다.




Fig. 2. Difference In Use Of Identity Loss In Interim Results

Identity mapping을 사용한 결과 Fig. 2와 같이 더 높은 성능을 도출하였다.

$$L_{identity}(G, R) = [\|G(y) - y\|_1] + [\|R(y) - y\|_1] \cdots (5)$$

본 모델에서는 식(5)의 손실함수를 사용한다.

1.4 Full Object

$$\begin{aligned} L(G, F, H, R, D_x, D_y, D_z) &= L_{GAN}(G, D_Y, X, Y) + L_{GAN}(R, D_Y, Z, Y) \\ &+ L_{GAN}(H, D_z, G(x), Z) + L_{GAN}(F, D_x, R(z), Z) \cdots (6) \\ &+ L_{cyc}(G, F, R, H) + L_{identity}(G, R) \end{aligned}$$

본 연구의 학습 모델은 식(6)의 전체 구조를 가진다. 단순히 CycleGAN을 2번 학습하는 것과 다르게 구분자 D_y 를 중복 학습할 수 있게 하여서 전체 순환적인 구조를 제작하였고, Identity mapping을 활용하여 학습이 원활히 진행될 수 있도록 하였다. 이런 과정을 통해 한 번의 학습으로 다중 속성 이미지 변경을 가능하게 하였고 제작한 학습 모델을 바탕으로 실험을 진행하였다. 이는 5장에서 서술한다.

2. Learning stabilization

2.1 Network Structure

높은 정확도를 위하여 생성자 네트워크 구조를 ResNet의 Residual block을 사용하였다. ResNet은 Encoder-decoder 구조와 유사하지만, Residual connection을 통해 값의 전달이 이루어져 존재하는 정보를 크게 잃지 않아 고해상도 처리에 효율적이고 정확도가 높아서 ResNet을 사용하였다. 구분자는 patchGAN[6][8][9]을 사용하여 많은 양의 파라미터를 줄이고 생성자가 생성하는 이미지를 단순히 구분자를 속이는 방향이 아닌 정답 이미지와 가깝게 만들도록 하였다.

2.2 Training Detail

GAN loss는 Cross entropy loss를 사용하기 때문에 기울기 값이 손실되는 문제가 발생한다. 그래서 이런 점을 고려하여 GAN loss를 대신하여 LSGAN의 Least square loss를 사용한다.

$$L_{GAN} = E_y [(D_y(y) - 1)^2] + E_x [(D_y(G(x)))^2] \cdots (7)$$

Least square loss는 GAN loss와 다르게 Cross entropy loss의 형태를 띠지 않고 식(7)과 같이 MSE loss 형태로 만들어 값을 잘 전달되도록 한다[12].

실험을 할 때마다 결과가 다른 현상을 해결하고자 replay buffer를 두어 주기적으로 생성자가 만든 이미지

를 다시 입력하여 구분자에게 재학습시킨다.

학습 세부사항으로는 시작 가중치를 10으로 두며 Batch size가 1인 Adam optimizer[7]을 사용한다. Learning rate는 0.0002로 사용한다. 또한, 실험 결과 100 epoch 부근 이후에서는 Fig. 3과 같이 더욱 좋지 않은 성능을 보여 100 epoch로 학습을 진행하였다.




Fig. 3. Discriminator D_y 's loss according to epoch

IV. Experiment

실험을 통해 본 모델을 활용한 이중 속성 변환이 기존 구조들과 비교하여 어떤 장점과 단점이 있는지 확인한다.

1. Experiment Models

본 실험에서는 GAN을 활용한 이미지-이미지 변환 구조인 CycleGAN, StarGAN[1] 과 Multi CycleGAN을 비교하는 실험을 진행한다.

2. Experiment Dataset

실험 데이터는 동일한 양의 The CelebFaces Attributes(CelebA) 데이터 셋[11]을 사용한다. CelebA 데이터 셋은 유명인들의 얼굴 이미지를 202599장 포함하고 있는 데이터 셋으로 속성 별로 구분이 되어있다. 실험에 사용한 데이터는 모자와 안경이 없는 금발의 사람, 남성, 금발여성, 여성 속성을 가진 데이터 3000장을 통해 학습을 진행하고 이와 별개의 이미지를 통해 실험을 진행한다. 또한, Multi CycleGAN은 남성, 여성, 금발의 사람 데이터를 사용하였고 StarGAN과 CycleGAN은 남성과 금발의 여성 데이터를 사용하였다.

3. Experiment Result

이중 속성 변환을 활용한 모델을 통하여 이미지-이미지 변환을 하였을 때 기존 변환 모델들과 비교하여 더 사실적인 이미지를 생산할 수 있는지, 입력 도메인의 형태를 잘 유지할 수 있는지, 적절한 속성 변환이 이뤄졌는지를 확인하기 위하여 실험을 진행하였다. 실험은 정성 평가로 진행되었으며 Fig. 4와 같은 결과를 확인하였다.

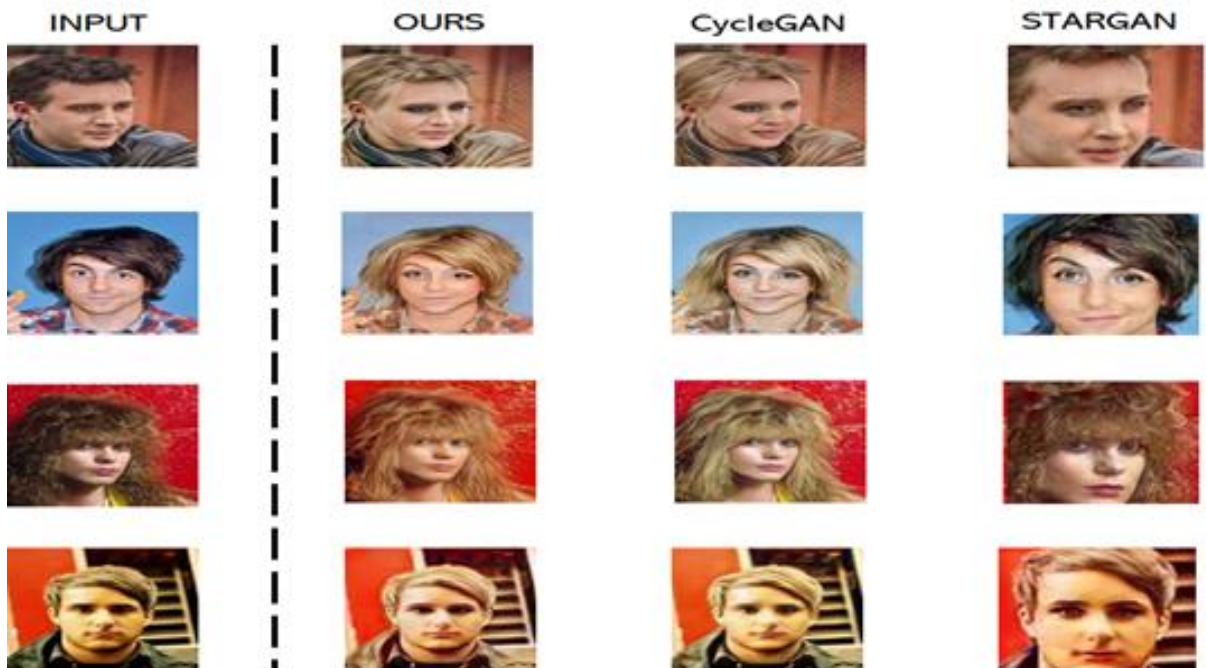


Fig. 4. Result of male to blonde female translation by structure

실험 결과 StarGAN은 원본을 유지하는 성능은 높게 나타났지만 적절한 속성 변환이 이루지 못했다. 이런 결과는 남자를 금발의 여성으로 변환하는 과정은 많은 변화가 필요한 과정이지만 StarGAN은 원본의 유지하는데 높은 성능을 보이기 때문에 나타났다. 이와 다르게 CycleGAN의 결과를 살펴보면 금발의 여성이라는 속성으로 많은 변화를 시도한다.

원본의 형태를 조금 벗어나지만 적절한 속성 변환을 하는 높은 성능을 보였다. 마지막으로 Multi CycleGAN은 원본의 형태 유지와 적절한 속성 변환 모두 높은 성능을 보인다.

CycleGAN은 목적 도메인으로 변환하는 이미지-이미지 변환의 역할을 잘 수행하는 구조이다. 때문에 CycleGAN을 활용한 Multi CycleGAN은 기존 높은 성능의 속성 적용을 기반으로 분할 학습을 이용한 속성별 학습이 이루어지기 때문에 목적 도메인에 과적합 되지 않고 적절한 속성 적용을 이룰 수 있었다.

V. Conclusions

본 연구는 이미지-이미지 변환에서 비지도 학습을 사용할 때 다중 속성 변환의 효용성을 알아보고자 하였다. 이를 위해 CycleGAN을 활용한 이중 속성 변환 구조인 Multi CycleGAN을 설계 및 구현하였으며 다른 구조들과 비교 실험을 진행하였다. 실험 결과 다중 속성 변환을 활용할 때 기존의 이미지-이미지 변환 구조보다 원본 이미지의 형태를 지키면서 목적 이미지에 유사하게 변환하였다. 이런 점으로 보아 다중 속성 변환을 활용한 이미지-이미지 변환이 데이터를 분할하여 학습할 수 있어 높은 성능을 보일 수 있다는 것을 확인하였다.

하지만 다중 변환의 특성상 더 많은 도메인을 처리해야 하며 이에 따라 매개변수의 양이 많아지므로 Table 1과 같이 다른 구조들보다 학습 시간이 길다는 단점이 있다.

Table 1. Learning Progress Time by Structure

구조	경과시간 (m)
CycleGAN	7835
StarGAN	2072
Multi-CycleGAN	11520

또한, Fig. 5와 같이 최종 결과물은 중간 결과물에 대한 의존도가 높아서 구조적으로 이 또한 고려해 주어야 한다.



Fig. 5. Example of final result failure due to intermediate result

이런 단점을 해결한다면 다중 속성 변환을 통한 이미지-이미지 변환은 더욱 높은 성능을 낼 수 있을 것이며 더 다양한 이미지 생산을 통해 많은 분야의 활용을 기대할 수 있다.

REFERENCES

- [1] Choi, Y., Choi, M., Kim, M., Ha, J. W., Kim, S., and Choo, J., "Stargan: Unified generative adversarial networks for multi-domain image to image translation", In Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 8789-8797, 2018
- [2] Gatys, L. A. and Ecker, A. S. and Bethge, M., "Image style transfer using convolutional neural network's", In Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 2414-2423, 2016
- [3] Girshick, R., "Fast r-cnn", In Proceedings of the IEEE international conference on computer vision, pp. 1440-1448, 2015
- [4] Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... and Bengio, Y., "Generative adversarial nets", In Advances in neural information processing systems, pp. 2672-2680, 2014
- [5] He, K., Zhang, X., Ren, S., and Sun, J., "Deep residual learning for image recognition", In Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 770-778, 2016
- [6] Isola, P., Zhu, J. Y., Zhou, T., and Efros, A. A., "image to image translation with conditional adversarial networks", In Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 1125-1134, 2017
- [7] Kingma, D. P., and Ba, J., "Adam: A method for stochastic optimization", arXiv preprint arXiv:1412.6980, 2014
- [8] Ledig, C., Theis, L., Huszár, F., Caballero, J., Cunningham, A., Acosta, A., ... and Shi, W., "Photo-realistic single image super-resolution using a generative adversarial network", In Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 4681-4690, 2017

- [9] Li, C., and Wand, M., "Precomputed real-time texture synthesis with markovian generative adversarial networks", In European conference on computer vision, pp. 702-716. Springer, Cham. 2016, October
- [10] Lin, J., Xia, Y., Wang, Y., Qin, T., and Chen, Z., "image to image translation with multi-path consistency regularization", arXiv preprint arXiv:1905.12498, 2019
- [11] Liu, Z., Luo, P., Wang, X., and Tang, X., "Deep learning face attributes in the wild", In Proceedings of the IEEE international conference on computer vision, pp. 3730-3738. 2015
- [12] Mao, X., Li, Q., Xie, H., Lau, R. Y., Wang, Z., and Paul Smolley, S., "Least squares generative adversarial networks", In Proceedings of the IEEE International Conference on Computer Vision, pp. 2794-2802, 2017
- [13] Mao, X., Shen, C., and Yang, Y. B., "Image restoration using very deep convolutional encoder-decoder networks with symmetric skip connections", In Advances in neural information processing systems, pp. 2802-2810, 2016
- [14] Radford, A., Metz, L., and Chintala, S., "Unsupervised representation learning with deep convolutional generative adversarial networks", arXiv preprint arXiv:1511.06434, 2015
- [15] Zhou, T., Krahenbuhl, P., Aubry, M., Huang, Q., and Efros, A. A., "Learning dense correspondence via 3d-guided cycle consistency", In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 117-126, 2016
- [16] Zhu, J. Y., Park, T., Isola, P., and Efros, A. A., "Unpaired image to image translation using cycle-consistent adversarial networks", In Proceedings of the IEEE international conference on computer vision, pp. 2223-2232, 2017

Authors



Seok Hee Jo received the A.S. degree in Computer Information Engineering from Inha Technical College, Korea, 2020 respectively. Mr. Jo entered the Inha Technical College in 2017 and graduated in 2020. He has

experience in IT practice and interested in IT and the fourth industrial revolution.



Kyu Cheol Cho received the B.S., M.S. and Ph.D. degrees in Computer Science and Information Engineering from Inha University, Korea, in 2005, 2007 and 2013, respectively. Dr. Cho joined the faculty of the Department

of Computer Science at Inha Technical College, Incheon, Korea, in 2016. He is currently a assistant professor in the Department of Computer Science, Inha Technical College. He is interested in cloud computing, green IT and web programming.